openTPU на VCU128: пути данных инференса (S=1, D=128, MCOLS=4, LANES=8)
сплошные — данные, пунктир — управление; на рёбрах — инструкция ISA

ПК (Python, upstream opentpu + EthTransport)

Engine / Board
компилятор, образ весов,
программы ISA, выборка токена

UDP: WRITE / READ / REG
(до 8 KiB на кадр)

VCU128

QSFP1 40G → l_ethernet
→ otpu_eth_bridge (UDP, eth_clk)

AXI-Lite: RUN, ARG, опрос HALTED

AXI4 128 bit
(загрузка весов, чтение логитов)

otpu_ctrl (s_ctl 0x00000)
CTRL / STATUS / ARG0..7
счётчики, буфер трассы

otpu_mem_ch ×2
CDC xclk / core / uclk
арбитраж хост ↔ ядро

RUN / загрузка IMEM

otpu_slice (core_clk 100 МГц)

SEQ + IMEM
окно 16 инструкций,
табло зависимостей

otpu_hbm_port ×2
beat 64 B → AXI3 2×256 bit
хеш по 8 псевдоканалам

DMA

DSTEP / STREAM
(Qwen3.5 DeltaNet)

VPU (+ SE)
8 полос FP32
exp2 / recip / rsqrt / Σ

ST

LD: x, cos, sin, нормы

VOP

VOP

TMEM
65536 × FP32 = 256 KiB
8 банков

4 порта AXI3, uclk 225 МГц

загрузчик программ

QACT / QST

ST (логиты)

LD

QUANT
8 FP32/такт, 2 прохода

QACT: INT8 + Sa

QST: K, Vᵀ + масштаб

порт SW
32 бит/такт

ACT RAM
4 строки × 128 блоков × 128 B
INT8 + масштабы

MM: FP32, ≤ 2 слова/такт

ACC / ASCALE

HBM2: каналы 0 и 1 (по 2 GiB)
веса · KV · программы · I/O · логиты

MM: стационарный
операнд (M ≤ 4 строк)

native, 2 канала
чередование по 64 B

порт B
128 B/такт

порт A
строки масштабов 32 B

MM: строки весов,
K-кэш, Vᵀ-тайлы

MM: Sw, dw / масштабы K

MXU
4 колонки × 128 INT8
FIFO чанков 1024×128 B
эпилог FP32