Слайс openTPU (otpu_slice) на VCU128: S = 1, D = 128, MCOLS = 4, LANES = 8, WIN = 16, core_clk 100 МГц

Сплошные — данные (подпись — ширина за такт), пунктир — управление, точки — обходные пути. Источник: slice_structure.dot, slice.md.

Обозначения

- поток весов MXU
- данные (порты, программа)
- раздача команд окном
- QUANT: QACT, QST
- управление ctrl / SEQ
- обходной путь

HALTED / ERROR / icount

RUN · ARG0..7 → R8..R15

otpu_ctrl (s_ctl 0x00000)
CTRL: RUN / LOAD / CLEAR · ARG0..7
STATUS · счётчики · буфер трассы

LOAD: PROG_ADDR, PROG_N

SEQ — otpu_seq

загрузчик программы
HBM → IMEM, 1 чанк = 4 инстр./такт
(старт и HALT CHAIN)

IMEM 4096 инструкций × 256 бит
чтение на такт вперёд

выборка + декод: 1 инстр./такт
R0..R15, LI / ADDI / LOOP (до 4 уровней)
w1..w3 += R[ra..rc]

окно WIN = 16 + табло
отпечатки диапазонов TMEM / HBM / ACT
RAW / WAR / WAW → старт самой старой готовой

программа

otpu_slice

команды из окна (старт по готовности)

QUANT — otpu_quant
8 FP32/такт, 2 прохода (max → коды)
буфер строки 1024 чанка · CSCALE / RSCALE

QST

QACT: 8 B/такт + {da, Sa}

порт SW
32 бит/такт + маска байт
QST (KV)

запись слов

память слайса: otpu_native_dram
2 канала (beat 64 B, чередование + CHASH)
→ otpu_mem_ch ×2 → otpu_hbm_port ×2 → HBM

ACT RAM — otpu_actram
4 строки × 128 блоков × 128 B INT8
+ {da, Sa} на (строку, блок)

запросы масштабов

строки масштабов

порт A
строки 32 B
масштабы MXU

чтение

веса, K-строки, V^T

порт B
128 B/такт (1024 бит)
DMA, затем поток MXU, загрузчик

запросы

чтение / запись чанков

BAR / GATHER

otpu_coll (общий на S слайсов)
BAR · GATHER: сегменты слайсов →
TMEM всех слайсов

LD / ST

DMA — otpu_dma
LD / ST: чанк 128 B ↔ 8 слов FP32/такт
буфер LD 128 чанков · WAITW · DSTEP/STREAM

4 строки × блок + Sa

issuer (ustart)
запросы N×KB чанков + строк масштабов

FIFO чанков
1024 × 128 B

FIFO масштабов
Sw, dw по блокам

DSTEP / STREAM (минуя TMEM)

VPU — otpu_vpu
8 полос FP32 (простые) + составные
(exp2, recip, rsqrt, log2) · дерево редукции
SE: хвост stream engine (DeltaNet)

1 чанк/такт

urel

8 слов/такт

VA, VB → запись: 8 слов/такт

TMEM — otpu_tmem

GATHER; RLD → R[rd]

систолический массив (urel)
4 колонки × 128 INT8·INT8
цепочки DSP48E2 по 16 · точная целая сумма

арбитр банков (каждый такт, всё-или-ничего)
приоритет: DMA > COLL > VPU > MXU drain > QUANT

FIFO результатов → эпилог, 2 полосы
i2f · ×Sw · ×Sa·2^{-16} · ACC / ASCALE / RMAX

ACC/ASCALE: старое значение

≤ 2 FP32/такт

65536 × FP32 = 256 KiB, 8 банков (адрес mod 8)
на FPGA — копия на каждый порт чтения
8 портов чтения: MXU, DMA, Q, VA, VB, Q2, Q3, COLL
4 порта записи: DMA, MXU, COLL, VPU

MXU — otpu_mxu (2 команды в работе)

8 FP32/такт из TMEM (Q, Q2, Q3)

Из doc/diagrams/slice_structure.dot и doc/slice.md; генератор variants/kicad/gen.py
vcu128_otpu_hog

Sheet: /
File: slice_kicad.kicad_sch

Title: Слайс openTPU (otpu_slice), VCU128 — структурная схема

Size: A3	Date: 2026-10-20	**Rev: 1**
KiCad E.D.A. 10.0.7		Id: 1/1