Слайс openTPU (otpu_slice) на VCU128: S = 1, D = 128, MCOLS = 4, LANES = 8, WIN = 16, core_clk 100 МГц

otpu_ctrl (s_ctl 0x00000)
CTRL: RUN / LOAD / CLEAR · ARG0..7
STATUS · счётчики · буфер трассы

LOAD: PROG_ADDR, PROG_N

HALTED / ERROR / icount

RUN · ARG0..7 → R8..R15

otpu_slice

SEQ — otpu_seq

загрузчик программы
HBM → IMEM, 1 чанк = 4 инстр./такт
(старт и HALT CHAIN)

IMEM
4096 инструкций × 256 бит
чтение на такт вперёд

выборка + декод: 1 инстр./такт
R0..R15, LI / ADDI / LOOP (до 4 уровней)
w1..w3 += R[ra..rc]

окно WIN = 16 + табло
отпечатки диапазонов TMEM / HBM / ACT
RAW / WAR / WAW → старт старшей готовой

BAR / GATHER

otpu_coll (общий на S слайсов)
BAR · GATHER: сегменты слайсов
→ TMEM всех слайсов

программа: HBM → загрузчик (порт B)

старт команд (конфликты в окне сняты)

QUANT — otpu_quant
8 FP32/такт, 2 прохода (max → коды)
буфер строки 1024 чанка
CSCALE / RSCALE

QACT: 8 B/такт + {da, Sa}

MXU — otpu_mxu (2 команды в работе)

issuer (ustart)
запросы N×KB чанков + строк масштабов

запросы

порт B
128 B/такт (1024 бит)
DMA, затем поток MXU,
загрузчик

чтение / запись чанков

FIFO чанков
1024 × 128 B

веса

порт A
строки 32 B: масштабы MXU

чтение строк

FIFO масштабов
Sw, dw по блокам

1 чанк/такт: веса, K-строки, V^T

память слайса
otpu_native_dram

2 канала, beat 64 B,
чередование + CHASH

→ otpu_mem_ch ×2
→ otpu_hbm_port ×2 → HBM

urel

ACT RAM — otpu_actram
4 строки × 128 блоков × 128 B INT8
+ {da, Sa} на (строку, блок)

4 строки × блок + Sa

систолический массив (urel)
4 колонки × 128 INT8·INT8
цепочки DSP48E2 по 16 · точная сумма

Sw, dw

порт SW
32 бит/такт + маска байт
QST (KV-кэш)

запись слов

LD / ST

DMA — otpu_dma
LD / ST: чанк 128 B ↔ 8 слов FP32
буфер LD 128 · WAITW · DSTEP/STREAM

DSTEP / STREAM (минуя TMEM)

VPU — otpu_vpu
8 полос FP32 + составные
exp2, recip, rsqrt, log2 · редукция
SE: хвост stream engine (DeltaNet)

8 слов/такт

VA, VB; запись 8 слов/такт

QST: K-строки и столбцы V^T

FIFO результатов → эпилог, 2 полосы
i2f · ×Sw · ×Sa·2^{-16} · ACC / ASCALE / RMAX

≤ 2 FP32/такт

ACC / ASCALE: старое значение

чтение 8 FP32/такт (Q, Q2, Q3)

TMEM — otpu_tmem

арбитр банков: каждый такт, всё-или-ничего
приоритет DMA > COLL > VPU > выгрузка MXU > QUANT

гранты банков

GATHER; RLD → R[rd]

65536 × FP32 = 256 KiB, 8 банков (адрес mod 8)
на FPGA — копия памяти на каждый порт чтения

8 портов чтения: MXU, DMA, Q, VA, VB, Q2, Q3, COLL
4 порта записи: DMA, MXU, COLL, VPU

Обозначения

- 128 B/такт (порт B, поток весов)
- 8 слов FP32/такт (TMEM)
- ≤ 32 B/такт, слова
- управление
- обход / старое значение

пересечение — разрыв в нижней линии